

Datenanalyse_Buergerhaushalt

Anthéa von Borowski

2026-01-16

Libraries

```
list.of.packages <- c("ggplot2", "here", "dplyr")
new.packages <- list.of.packages[!(list.of.packages %in% installed.packages()[,"Package"])]
if(length(new.packages)) install.packages(new.packages)

for(pkg in list.of.packages){
  library(pkg, character.only = TRUE)
}

## here() starts at /Users/antheavonborowski/Documents/Coding Projects/Projekt_Buergerhaushalt

##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##   filter, lag

## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union
```

Datensatz

Die verwendeten Daten wurden in `scraper.ipynb` gesammelt, mithilfe Web-Scraping Methoden.

Daten importieren

```
data <- as.data.frame(read.csv(here("dataset", "output.csv")))
```

Daten bearbeiten

Abfall, Sauberkeit -Abfalleimer -Abfallentsorgung -Hundekot -öffentliche Toiletten -Recycling -Reinigung -Weitere Busse, Bahnen (ÖPNV) -Gleisbegrünung -Haltestellen -Lärm -Seilbahn -Taktung -Tarife, Tickets -Verbindungen -Weitere Energie, Umwelt -Energie sparen -erneuerbare Energien -Feinstaub, Luft -Klima -Weitere Gesundheit Grünflächen, Wald, Friedhöfe -Bäume -Fluß, See, Teich -Friedhöfe -Sitzbänke -Spielplätze -Weitere Kinder, Jugend, Familie -Jugendarbeit -Kitas -Weitere Kultur -Feste und Feiern -Weitere Schulen, Bildung -Betreuung -Sanierung, Schulbau -Weitere Senioren Sicherheit, Ordnung -Kontrollen -Tiere -Weitere Soziales Sport, Bäder -Bäder -Sonstige Sportanlagen -Sporthallen -Sportplätze -Weitere Stadtplanung, Städtebau -Denkmalschutz -Plätze -Stadt am Fluss -städtische Gebäude -Straßengestaltung -Stuttgart 21 -Weitere Steuern, Finanzen Verkehr -Ampeln -Diesel Fahrverbot -Durchfahrverbote -Einbahnstraße -Elektro-Mobilität -Fußgänger -Fußgängerüberweg -Fußweg -Geschwindigkeitskontrolle -Kreisverkehr -Lärm -Park+Ride -Parken -Radverkehr -Radwege -Straßenbau -Straßenbeleuchtung -Straßensanierung -Tempo 20, 30, 40, 50 -Verkehrsberuhigung -Verkehrskontrolle -Verkehrsschilder -Weitere Verwaltung Wirtschaft Wohnungsbau, Wohnen Zusätzliche Themen

```
data$status <- gsub("\n", "", data$status)
data$status <- trimws(data$status)

data$kostenneutral <- data$wirkung == "kostenneutral"
data$sparidee <- data$wirkung == "Sparidee"
data$ausgabe <- data$wirkung == "Ausgabe"
data$einnahme <- data$wirkung == "Einnahme"
```

Plots

You can also embed plots, for example:

```
## # A tibble: 8 x 5
##   year total n_wirkung_ausgabe n_wirkung_neutral n_wirkung_sparidee
##   <dbl> <int>          <dbl>          <dbl>          <dbl>
## 1  2011  1682          0.687          0.120          0.113
## 2  2013  2843          0.758          0.140          0.0654
## 3  2015  3122          0.703          0.184          0.0573
## 4  2017  2664          0.729          0.183          0.0364
## 5  2019  2901          0.732          0.194          0.0314
## 6  2021  2156          0.719          0.197          0.0380
## 7  2023  1693          0.835          0.0986         0.0325
## 8    NA    11           1           0           0
```

Plots

Jetzt generieren wir deskriptive Plots, um die Daten deskriptiv zu visualisieren.

Anzahl der Angeboten pro Jahr.

```
ggplot(grouped_year, aes(x = year, y = (total), label = total)) +
  geom_line() +
  geom_point() +
  labs(
```

```

x = "Jahr",
y = "Anzahl der Angeboten",
title = "Anzahl der Angeboten bei Bürgerhaushalte zwischen 2013 und 2023"
) +
theme_light() +
scale_y_continuous(
  limits = c(0, max(grouped_year$total)),
  breaks = seq(0, max(grouped_year$total), by = 400)
)+
scale_x_continuous(breaks= seq(2013, 2023, by = 1))

```

```


## Warning: Removed 1 row containing missing values or values outside the scale range
## ('geom_line()').

```

```

## Warning: Removed 1 row containing missing values or values outside the scale range
## ('geom_point()').

```



```

ranks_topics <- data %>%
  count(year, thema) %>%
  mutate(
    percent = n / sum(n) * 100
  ) %>%
  group_by(year) %>%
  arrange(desc(percent), .by_group = TRUE) %>%

```

```

slice_head(n = 5) %>%
ungroup()

ggplot(ranks_topics, aes(x = year, y= percent , color = thema)) +
  geom_point() +
  geom_line() +
  labs(
    x = "Jahr",
    y = "Anteil (%)",
    title = "Top 5 Themen pro Jahr",
    color = "Legend"
  ) +
  theme_light() +
  scale_x_continuous(breaks = seq(2013, 2023, by = 2)) +
  scale_y_continuous(
    limits = c(0, max(ranks_topics$percent)),
    breaks = seq(0, max(ranks_topics$percent), by = 2)
  )

```

```


## Warning: Removed 5 rows containing missing values or values outside the scale range
## ('geom_point()').

```

```

## Warning: Removed 5 rows containing missing values or values outside the scale range
## ('geom_line()').

```



```

data$reviewed <- data$status != ""
data$considered <- data$reviewed & ! data$status %in% c("Stadt ist nicht zuständig", "vorher bereits umg", "Gemeinderat hat abgelehnt", "wird nicht umgesetzt")
data$refused <- data$status %in% c("Gemeinderat hat abgelehnt", "wird nicht umgesetzt")
data$accepted <- data$status %in% c("umgesetzt", "wird umgesetzt", "wurde umgesetzt", "Gemeinderat hat", "Gemeinderat entscheidet später", "kein")
data$pending <- data$status %in% c("ist offen", "wird geprüft", "Gemeinderat entscheidet später", "kein")

status_year <- data[!data$pending,] %>%
  group_by(year) %>%
  summarise(
    n_reviewed = sum(reviewed == T),
    n_considered = sum(considered == T),
    n_refused = sum(refused == T),
    n_accepted = sum(accepted == T),
    n_pending = sum(pending == T),
    anteil_reviewed = mean(reviewed == T),
    anteil_considered = mean(considered == T),
    anteil_refused = n_refused / n_considered,
    anteil_accepted = n_accepted / n_considered,
    anteil_pending = n_pending / n()
  )

status_year

```

```

## # A tibble: 7 x 11
##   year n_reviewed n_considered n_refused n_accepted n_pending anteil_reviewed
##   <dbl>      <int>      <int>      <int>      <int>      <int>      <dbl>
## 1  2011         227         219         42         49         0         1
## 2  2013         267         263         68         91         0         1
## 3  2015         196         195         25         59         0         1
## 4  2017         196         193         24         27         0         1
## 5  2019         221         219         13         65         0         1
## 6  2021         170         169         13         64         0         1
## 7  2023         103         102          8         35         0         1
## # i 4 more variables: anteil_considered <dbl>, anteil_refused <dbl>,
## #   anteil_accepted <dbl>, anteil_pending <dbl>

```

```
sum(data$reviewed)
```

```
## [1] 1573
```

```
summary(data[data$considered == T,]$rank)
```

```

##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    1.0   57.0   131.0   292.1  420.0  2600.0

```

```
summary(data[data$reviewed == T,]$rank)
```

```

##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    1.0   57.0   130.0   290.6  419.0  2600.0

```

```
reg <- glm(reviewed ~ rank + ausgabe + sparidee + einnahme, data = data, family = binomial("logit"))
exp(reg$coefficients)
```

```
## (Intercept)      rank  ausgabeTRUE sparideeTRUE einnahmeTRUE
## 1.2040714    0.9955901    1.6214068    0.8342282    1.0097183
```

```
summary(reg)
```

```
##
## Call:
## glm(formula = reviewed ~ rank + ausgabe + sparidee + einnahme,
##      family = binomial("logit"), data = data)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  0.185709   0.096274   1.929   0.0537 .
## rank        -0.004420   0.000114 -38.774 < 2e-16 ***
## ausgabeTRUE  0.483294   0.095038   5.085 3.67e-07 ***
## sparideeTRUE -0.181248   0.172117  -1.053  0.2923
## einnahmeTRUE  0.009671   0.184872   0.052  0.9583
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##    Null deviance: 10496  on 17060  degrees of freedom
## Residual deviance:  6293  on 17056  degrees of freedom
## (11 observations deleted due to missingness)
## AIC: 6303
##
## Number of Fisher Scoring iterations: 8
```